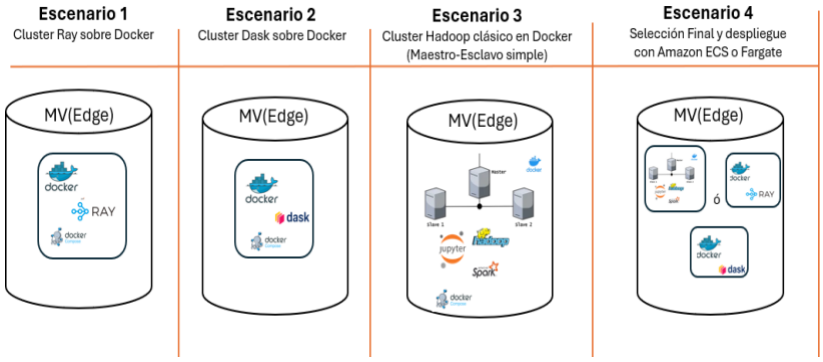
Universidad Pontificia Comillas

AQUITECTURA BIG DATA

PROYECTO

Fecha Inicio	**03/09/2025**
Duración Estimada	**14 Semanas.**
Título	**BENCHDATA:** Evaluación comparativa de arquitecturas distribuidas basadas en contenedores para flujos de trabajo de ciencia de datos.
Supervisores Proyecto	Guillermo Gallego Reina: ggallego@icai.comillas.edu Ignacio Pérez Torres: iptorres@icai.comillas.edu Marcos Llorens Martínez: mllorens@icai.comillas.edu
Área/s temáticas principales	Big Data, Arquitectura, Docker, Ray, Dask, Spark, Hadoop, Jupyter Notebook, Microservicios, Redes, Infraestructura.
Descripción del proyecto / Esquema arquitectura	Contamos con un entorno de producción distribuido, compuesto por 4 o 5 nodos, gestionados a través de **Cloudera Manager**. Este entorno está siendo usado tanto para procesos de producción como para tareas de desarrollo. Como resultado, con frecuencia se produce una saturación de recursos, lo que afecta el rendimiento y la estabilidad del sistema para todos los equipos que lo utilizan. Proponemos analizar distintas alternativas para crear un **entorno de desarrollo separado** del de producción, que sea **estable, escalable y accesible** para los diferentes grupos de **Data Scientists** de la compañía. Este entorno permitiría trabajar con mayor autonomía, sin interferencias ni cuellos de botella por compartir recursos críticos. Para poder comparar el rendimiento de los distintos escenarios propuestos, vamos a usar un ejercicio sencillo y medible: **calcular el número π usando el método de Montecarlo**. Los principales requisitos funcionales sobre los que se sustenta el proyecto son: i. Cada grupo implementará una función que genera puntos aleatorios y calcula cuántos de ellos caen dentro de un cuarto de círculo adaptados a cada escenario: Ray, Dask, Pyspark. ii. Se utilizará instancias AWS EC2 basados en contenedores. iii. Los escenarios propuestos son: • Escenario 1: Clúster Ray. • Escenario 2: Clúster Dask. • Escenario 3: Clúster Hadoop.

	iv. Los escenarios estarán disponibles: • https://github.com/IMATARTE/ArquitecturaBIGDATA.git v. Comprobar que todas las herramientas de los escenarios como los dashboard y entornos de monitorización funcionan correctamente. vi. Objetivo: • Desplegar los escenarios disponibles en el repositorio. • La función creada se ejecutará múltiples veces para cada uno de los escenarios con diferentes configuraciones (variando el número de nodos y puntos). • **Worker**: [1, 2, 3]. • **Número de Puntos:** [5M, 10M, 50M] • Se medirán: **Tiempo de proceso, Velocidad (Número de puntos / Tiempo de proceso) y Estimación del valor pi.** • Se realizará una representación gráfica para cada una de las mediciones y por cada escenario propuesto. vii. En cada Sprint se desplegará cada escenario propuesto. viii. Presentación de resultados de cada una de las pruebas realizadas durante los Sprints. ix. Esquema arquitectura 
Recursos Requeridos	Componer los grupos de trabajo. Cada grupo de alumnos serán empleados de distintas consultoras expertas en Arquitectura Big Data. Tener acceso a las cuentas de AWS correspondientes a cada grupo. Tener los conocimientos necesarios para montar el end to end del proyecto.
Metodología	El Proyecto estará basado en Scrum con el objetivo de proponer un modo de trabajo ágil. • Sprint Planning. • Daily Scrum. • Sprint Review. • Sprint Retrospective. Los equipos estarán compuestos por un máximo de 3 personas.

Entregas / Objetivo	Se realizará una documentación donde se plasme el despliegue de los diferentes escenarios con la conclusión del escenario óptimo para el objetivo propuesto.